

1) Формулы для FLOPS

у нашей сети есть следующие слои: conv, max pool, avg pool, linear, relu. Для них и выведем формулы:

• conv 2d:

операций на 1 kernel: $2(\text{kernel-size} * \text{kernel-size} * \text{inp-dim})$, 2 - так как есть сложение и умножение, потом на каждый параметр в kernel всего kernel-ов:

$$\left(\frac{(\text{inp-size} + 2 \text{pdd} - \text{kernel-size})}{\text{stride}} + 1 \right)^2 - \text{смотрим сколько сдвигов можно сделать}$$

и +1, так как надо учесть 1 позицию, квадрат, так как как вычисляем вверх и вниз.

итого:

$$BS * 2(\text{kernel-size} * \text{kernel-size} * \text{inp-dim}) * \left(\frac{(\text{inp-size} + 2 \text{pdd} - \text{kernel-size})}{\text{stride}} + 1 \right)^2 * \text{output-dim}$$

• max pool

кол-во сверток так-же считается, как и у conv

кол-во операций в kernel:

$(\text{kernel-size}^2 - 1)$ то есть кол-во элементов без 1, так как мы сравниваем

$$BS * \text{inp-dim} * (\text{kernel-size}^2 - 1) * \left(\frac{(\text{inp-size} + 2 \text{pdd} - \text{kernel-size})}{\text{stride}} + 1 \right)^2$$

• avg pool

как max, но кол-во операций в kernel

kernel-size^2 , ибо там добавляется генерация

• linear

матрица весов: $(\text{input-size} * \text{output-size})$ и умножаем на 2, так как потом надо сложить в нейронах все + надо добавить bias, итого:

$$2(\text{input-size} * \text{output-size}) + \text{output-size} * BS$$

* relu:

$$\text{input-size} * BS$$

BS - batch size

② Memory

память нам нужна для двух вещей 1) параметры модели
2) активации и данные, спол те же

• conv 2d

params:

$$\text{input-channel} \times \text{kernel-size}^2 \times \text{output-channel}$$

activations:

$$BS \times \left(\frac{\text{input-len} + 2\text{pad} - \text{kernel}}{\text{stride}} + 1 \right)^2 \times \text{output-dim}$$

• max_pool, avg_pool:

activations:

$$BS \times \left(\frac{\text{input-len} + 2\text{pad} - \text{kernel}}{\text{stride}} + 1 \right)^2 \times \text{input-channel}$$

• Linear

params:

$$(\text{input-size} \times \text{output-size}) + \text{output-size}$$

activations:

$$BS \times \text{output-size}$$

в зависимости от типа данных 3D
еще все перемножается на кол-во батчей
помимо этого есть еще промежуточные
тензоры, которые необходимы для хранения
значения загрузки памяти, на пример в
linear $(\text{input-size} \times \text{output-size})$ до суммиро-
вания