Deep Learning on a Data Diet: Finding Important Examples Early in Training

Можно ли уже в начале обучения определить, какие объекты датасета важнее всего для качества сети?

01

Полный датасет

50 000 изображений

02

Раннее обучение

Оценка важности

03

Data Pruning

Удаление примеров

04

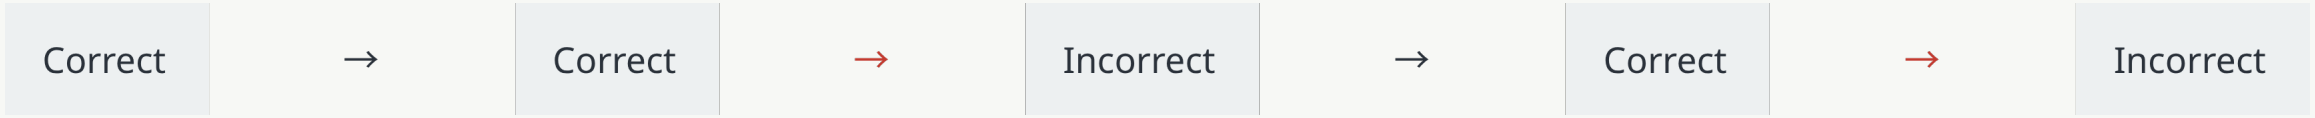
Сокращённый датасет

25 000 изображений

ПРОБЛЕМА · DATA PRUNING

Data Pruning: как выбрать важные примеры? С чем сравнивают авторы свой подход

Один из предыдущих подходов - Forgetting Score. Примеры, которые модель практически никогда не забывает (то есть после того, как она предсказала верный класс, она и дальше предсказывает для него верный класс), часто можно удалить без заметного ухудшения качества. Однако он требует отслеживания динамики обучения на протяжении значительного числа шагов. Их оценки хорошо коррелировали с окончательными только после примерно 25 эпох стабилизировались около 75 эпох из 200.



Красные переходы обозначают forgetting events. Редко забываемые примеры часто избыточны.

Сигнал появляется поздно

ResNet18, CIFAR-10: хорошая корреляция примерно после 25 эпох; стабилизация около 75.

Цель авторов

Получить аналогичный сигнал через несколько эпох, не ожидая значительной части обучения.

МЕТОД · GRAND

GraNd: важность примера измеряется нормой градиента

$$\mathrm{GraNd}_t = \mathrm{E}_{w_t} \left\| \nabla_{w_t} \ell(p(w_t, x), y) \right\|_2$$

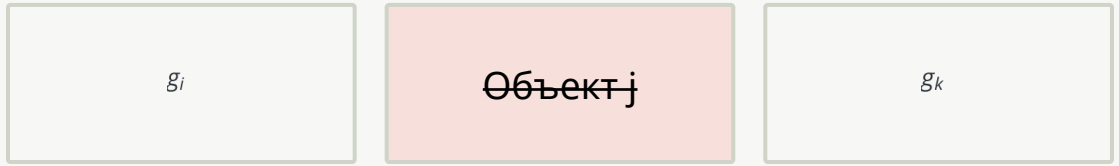
Ожидаемая L2-норма градиента loss ℓ по параметрам w_t для предсказаний p; ожидание по случайным траекториям обучения.

Почему градиент показывает важность примера?

При обучении каждый пример вносит свой вклад в обновление весов нейросети. Если убрать один пример из датасета, направление обучения может измениться. Авторы хотят понять, насколько сильно оно изменится. Они показывают, что влияние удаления примера на изменение ошибки модели ограничено величиной его градиента. Поэтому примеры с маленькими градиентами потенциально можно удалять без существенного влияния на обучение.

Удаление объекта меняет шаг слабо

Если убрать объект из mini-batch, шаг обучения меняется несильно.



Mini-batch с удалённым объектом: при удалении объекта результирующий шаг меняется несильно



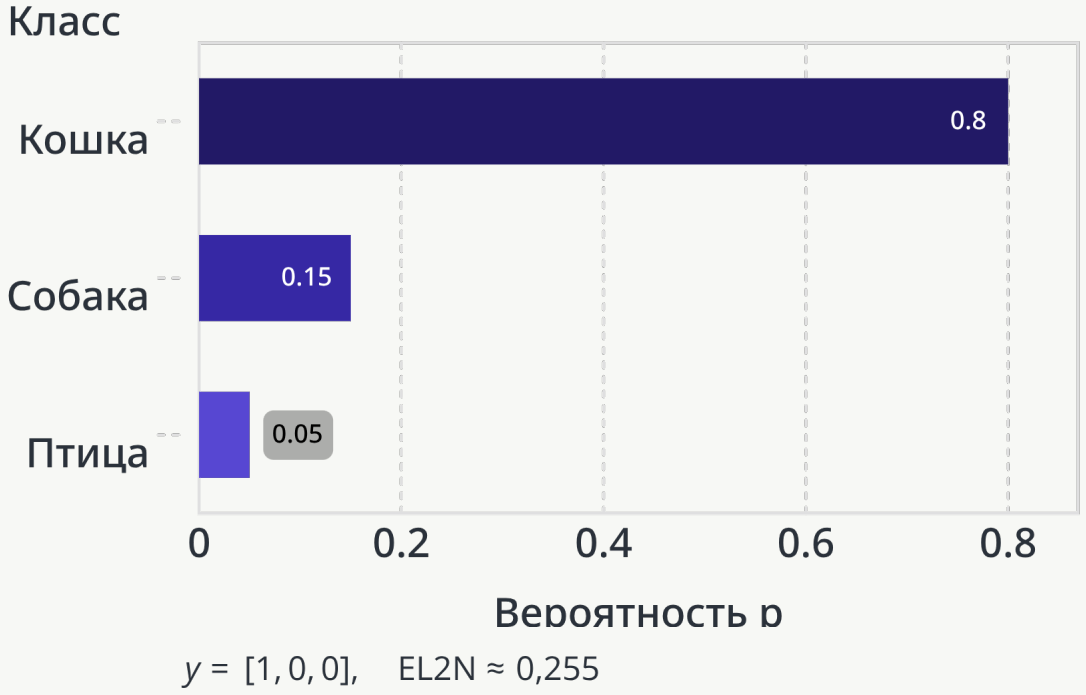
Малый GraNd ограничивает влияние на шаг сверху. Большой GraNd означает потенциально сильное влияние, **но не гарантирует пользу**.

МЕТОД · EL2N

EL2N: GraNd без градиентов по параметрам

$$\mathrm{EL2N}_t = \mathrm{E}_{w_t} \left\| p(w_t, x_i) - y_i \right\|_2$$

p - softmax-вероятности; y - one-hot.



$y = [1, 0, 0]$, EL2N ≈ 0,255

Условный пример: $p = [0.8, 0.15, 0.05]$

Low EL2N: уверенно правильный ответ. High EL2N: предсказание далеко от метки.

Почему EL2N может заменить GraNd?

GraNd оценивает важность примера через градиент по всем весам нейросети, но вычислять его достаточно затратно. Авторы показывают, что величина этого градиента связана с ошибкой предсказания модели. При определённых предположениях чем больше предсказание отличается от правильной метки, тем больше и градиент по весам. Поэтому вместо вычисления полного градиента можно использовать более простой показатель - EL2N.

При примерно ортогональных и сопоставимых по норме градиентах логитов:

$$\left\| \nabla_w \ell \right\|_2 \propto \left\| p - y \right\|_2$$

Приближение, не строгое равенство.

GraNd требует градиентов по параметрам; EL2N использует только вероятности и метки.

ЭКСПЕРИМЕНТАЛЬНЫЙ ПРОТОКОЛ

Как авторы проверяют эффективность EL2N?

Метод проверяли на трёх разных датасетах: CIFAR-10, CIFAR-100 и CINIC-10.

ДАТАСЕТ	ИЗОБРАЖЕНИЯ	КЛАССЫ
CIFAR-10	50 000	10
CIFAR-100	50 000	100
CINIC-10	180 000 · train + validation	10

01	02	03	04	05
Обучить	**Оценить**	**Отобрать**	**Переобучить**	**Сравнить**
Несколько эпох	EL2N каждого изображения; среднее по 10 запускам	Сортировка; удалить минимальные	Новую модель с нуля	Полный датасет и random pruning

ResNet18 / ResNet50; SGD с Nesterov momentum. lr 0.1; momentum 0.9; weight decay 0.0005. Batch 128 (CIFAR), 256 (CINIC-10). 200 эпох; lr в 5 раз ниже после эпох 60, 120, 160.

Итоговая accuracy усредняется по 4 обучениям. Число SGD-итераций и lr schedule сохраняются.

МРЕЗУЛЬТАТЫ · PRUNING

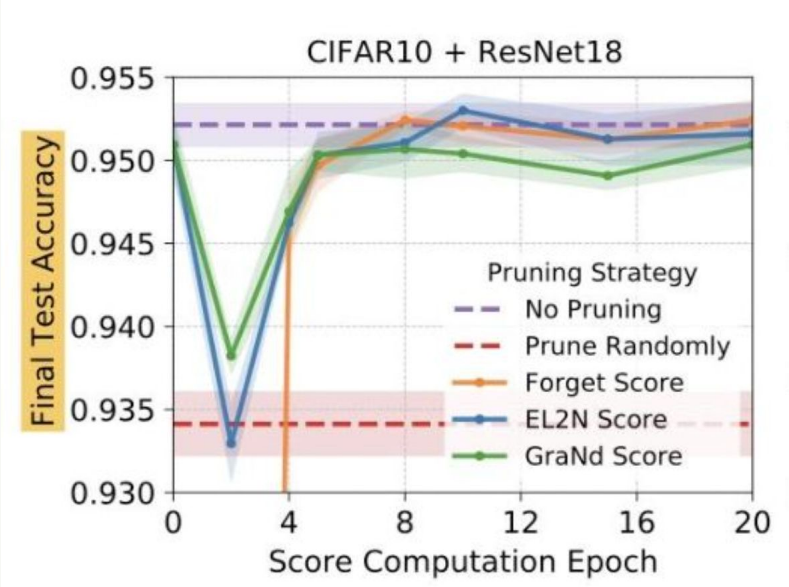
EL2N позволяет удалять данные без потери качества

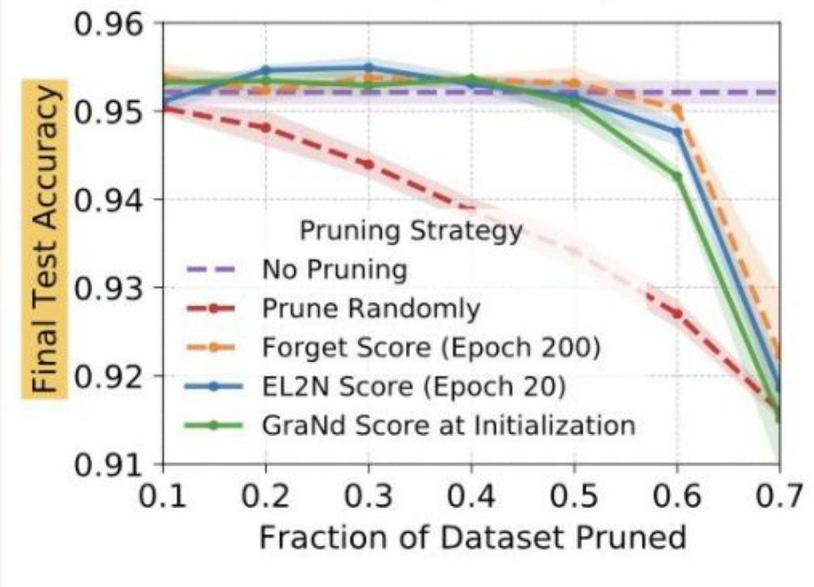
до 50%

CIFAR-10 · без ухудшения test accuracy

около 25%

CIFAR-100 · без ухудшения test accuracy





Ранний score уже хорошо ранжирует примеры. При сильном pruning accuracy резко падает, вероятно из-за недостаточного покрытия распределения.

ИНТЕРПРЕТАЦИЯ · СЛОЖНОСТЬ И ПОЛЬЗА

High EL2N ≠ High usefulness

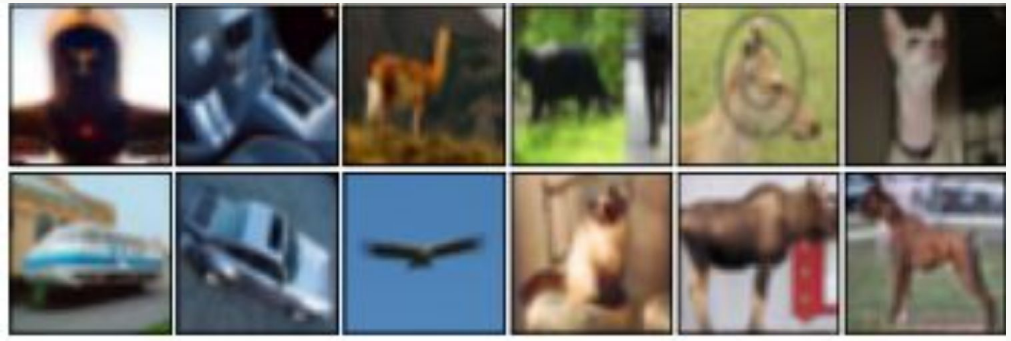
Low EL2N

Модель хорошо распознаёт объект.



High EL2N

Большие ошибки, но не обязательно польза для обобщения.

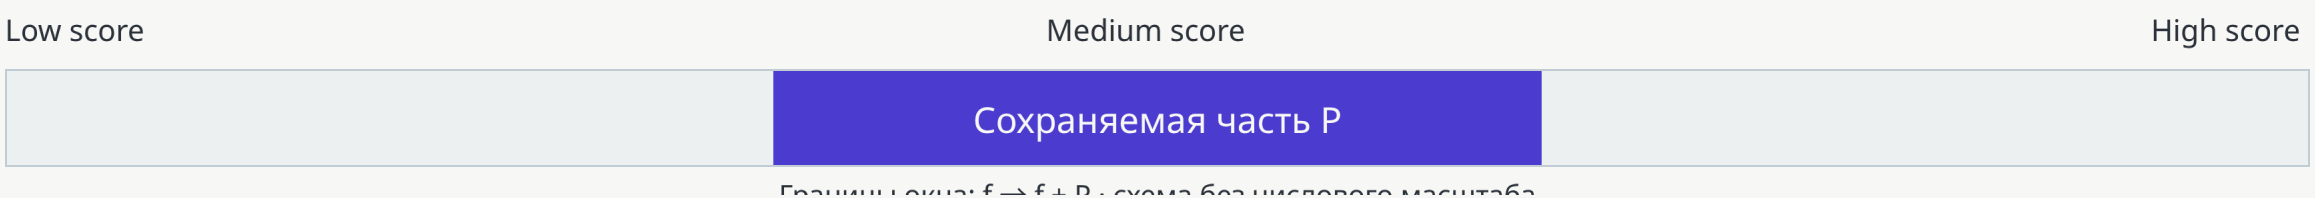


Высокий EL2N может означать полезный сложный пример, редкий ракурс, необычный фон, плохое качество, ошибку разметки или нетипичный объект.

Самые сложные примеры нельзя автоматически считать самыми полезными.

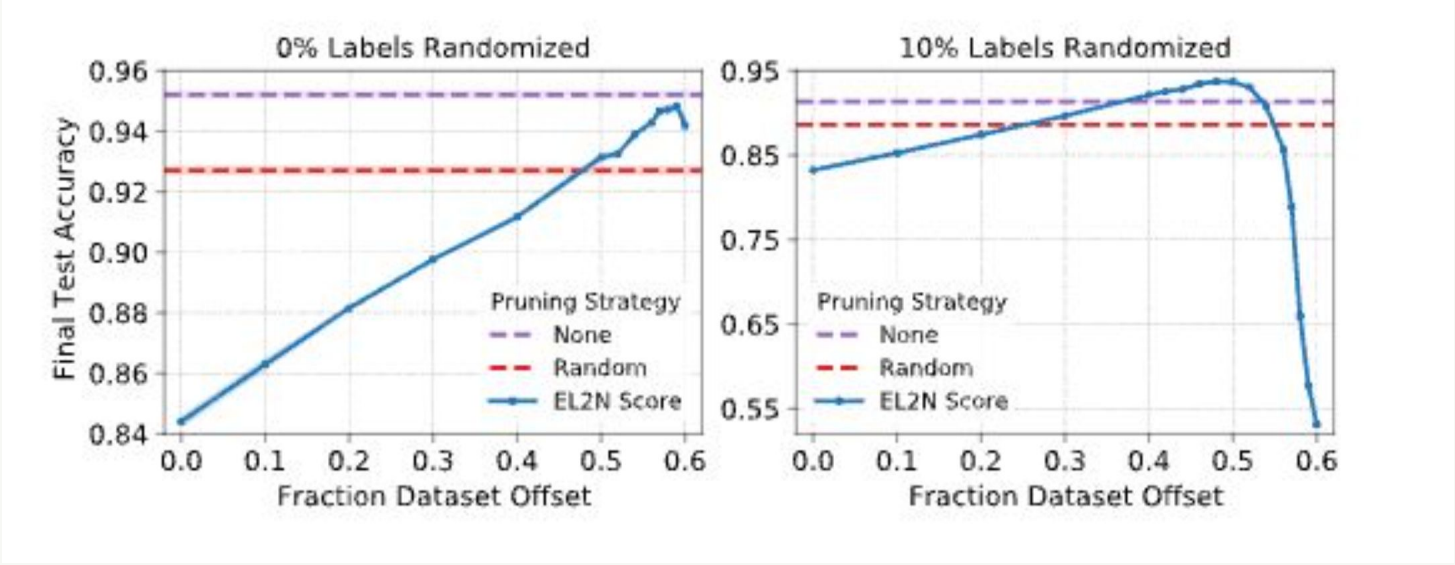
ОТБОР · SLIDING WINDOW

Sliding Window: исключаем не только лёгкие примеры



Границы окна: $f \to f + P$ · схема без числового масштаба

CIFAR-10, ResNet18; 40% данных; EL2N на 10-й эпохе. Чистые метки против 10% случайно изменённых.



РЕЗУЛЬТАТЫ И ГРАНИЦЫ ПРИМЕНИМОСТИ

Основные результаты и ограничения метода

Результаты

- Важность проявляется рано: хватает нескольких эпох.
- EL2N приближает GraNd
- CIFAR-10: около половины данных удаляется без потери качества; экономия вычислений не обязательно двукратная.
- Самые сложные примеры не всегда полезнее; sliding window исключает экстремальный хвост.

Что ограничивает метод

- Предварительное обучение и усреднение по запускам.
- Проверка в основном на малых vision-датасетах.

EL2N оценивает сложность примеров рано, но сложность не значит полезность.